

Visión por Computadora I


Ing. Maxim Dorogov
(mdorogov@fi.uba.ar)

Esp. Ing. Leandro Torrent
(ingtorrentleandro@gmail.com)

Laboratorio de Sistemas Embebidos -FIUBA



OPERADORES DE PÍXEL



Consideramos a las imágenes como funciones discretas 2D que mapean un dominio de coordenadas (u, v) a un conjunto discreto de valores $P = I(u, v)$

También podemos combinarlas:


- $g(\bar{x}) = h(f_0(\bar{x}), \dots, f_n(\bar{x}))$

Es decir, una imagen de salida $g(\bar{x})$ es función $h(f(\bar{x}))$ de una o más imágenes de entrada $f_i(\bar{x})$

- x : Dominio N-dimensional
- En imágenes discretas $x = (u, v)$
- $g(u, v) = h(f(u, v))$



OPERADORES DE PÍXEL



The dress

🌐 15 languages ▾

Article Talk

Read View source View history Tools ▾

From Wikipedia, the free encyclopedia

This article is about the viral phenomenon. For other uses, see [The Dress](#).

The dress was a [viral phenomenon](#) on the [Internet](#) in 2015. Viewers of the image disagreed on whether the [dress](#) depicted in a photograph was coloured black and blue, or white and gold. The phenomenon revealed differences in human colour perception, which have been the subject of ongoing scientific investigations into [neuroscience](#) and [vision science](#), producing a number of papers published in peer-reviewed scientific journals.

The phenomenon originated from a washed-out colour photograph of a dress posted on the [social networking service Facebook](#). Within a week, more than ten million [tweets](#) had mentioned the dress, using [hashtags](#) such as [#thedress](#), [#whiteandgold](#), and [#blackandblue](#). Although the dress was eventually confirmed to be coloured black and blue,^{[1][2]} the image prompted much online discussion of different users' perceptions of the colour of the dress. Members of the scientific community began to investigate the photograph for new insights into human [colour vision](#).


The dress was identified as a product of the retailer Roman Originals, which experienced a major surge in sales of the dress as a result of the incident. The retailer produced a one-off version of the dress in white and gold as part of a charity campaign.^[3]



OPERADORES DE PÍXEL

Algunas definiciones

- **Contraste:** Diferencia entre el valor de intensidad máximo y mínimo en una imagen.
- **Rango dinámico:** Se caracteriza por los niveles de intensidad que tienen los diferentes píxeles en la imagen. Rango dinámico máximo en 8 bits: 256 valores.
- ❑ Podemos aumentar el contraste aplicando transformaciones sencillas a los valores de los píxeles presentes en la imagen.
- ❑ Para modificar el rango dinámico se utilizan técnicas mas complejas ya que es necesario generar valores adicionales de intensidad (por ejemplo mediante interpolación) que no formaban parte de la imagen original.
- ❑ Es deseable trabajar con imágenes de gran rango dinámico ya que se minimizan los efectos de degradación durante su procesamiento y las redundancias presentes en los niveles de intensidad se utilizan en la compresión.



Derecha: Imagen original sin compresión

Izq: Imagen comprimida a 10 niveles de intensidad (muy bajo rango dinámico)




Bajo contraste

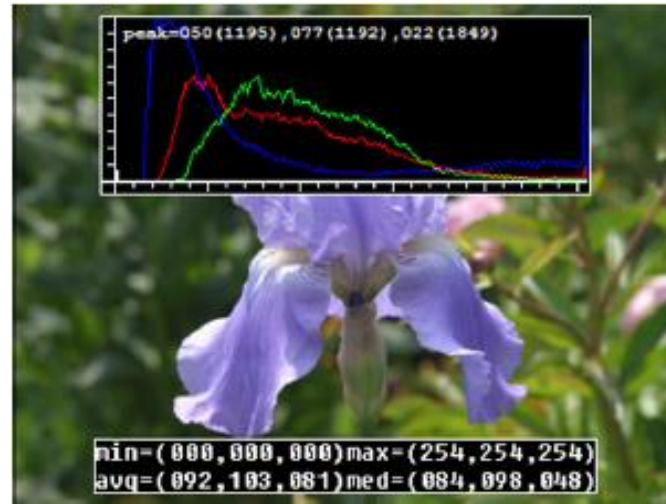


Alto contraste






Original



$a=1, b=16$



$a=1.1, b=0$

OPERADORES DE PÍXEL


- Un procesamiento común es:

$$g(x) = a.f(x) + b$$

- Donde
 - $a > 0$ es la ganancia y controla el contraste
 - b es el bias y controla el brillo
- También podría ser: $g(x) = a.f(x) + b(x)$



TRANSFORMACIONES PLANARES








$$\bar{\mathbf{x}}' = \begin{bmatrix} \mathbf{I} & \mathbf{t} \\ \mathbf{0}^T & 1 \end{bmatrix} \bar{\mathbf{x}}, \quad \mathbf{R} = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}$$

Traslación

Rotación

$$\mathbf{x}' = \begin{bmatrix} s\mathbf{R} & \mathbf{t} \end{bmatrix} \bar{\mathbf{x}} = \begin{bmatrix} a & -b & t_x \\ b & a & t_y \end{bmatrix} \bar{\mathbf{x}},$$

Rotación, escalado y traslación

Transformation	Matrix	# DoF	Preserves	Icon
translation	$\begin{bmatrix} \mathbf{I} & \mathbf{t} \end{bmatrix}_{2 \times 3}$	2	orientation	
rigid (Euclidean)	$\begin{bmatrix} \mathbf{R} & \mathbf{t} \end{bmatrix}_{2 \times 3}$	3	lengths	
similarity	$\begin{bmatrix} s\mathbf{R} & \mathbf{t} \end{bmatrix}_{2 \times 3}$	4	angles	
affine	$\begin{bmatrix} \mathbf{A} \end{bmatrix}_{2 \times 3}$	6	parallelism	
projective	$\begin{bmatrix} \tilde{\mathbf{H}} \end{bmatrix}_{3 \times 3}$	8	straight lines	



OPERADORES DE PÍXEL

- Los operadores de píxel lineales admiten superposición:

$$h(f_0 + f_1) = h(f_0) + h(f_1)$$

- Otra aplicación (transición entre dos imágenes):

$$g(x) = (1 - \alpha) \cdot f_0(x) + \alpha \cdot f_1(x) \quad 0 < \alpha < 1$$


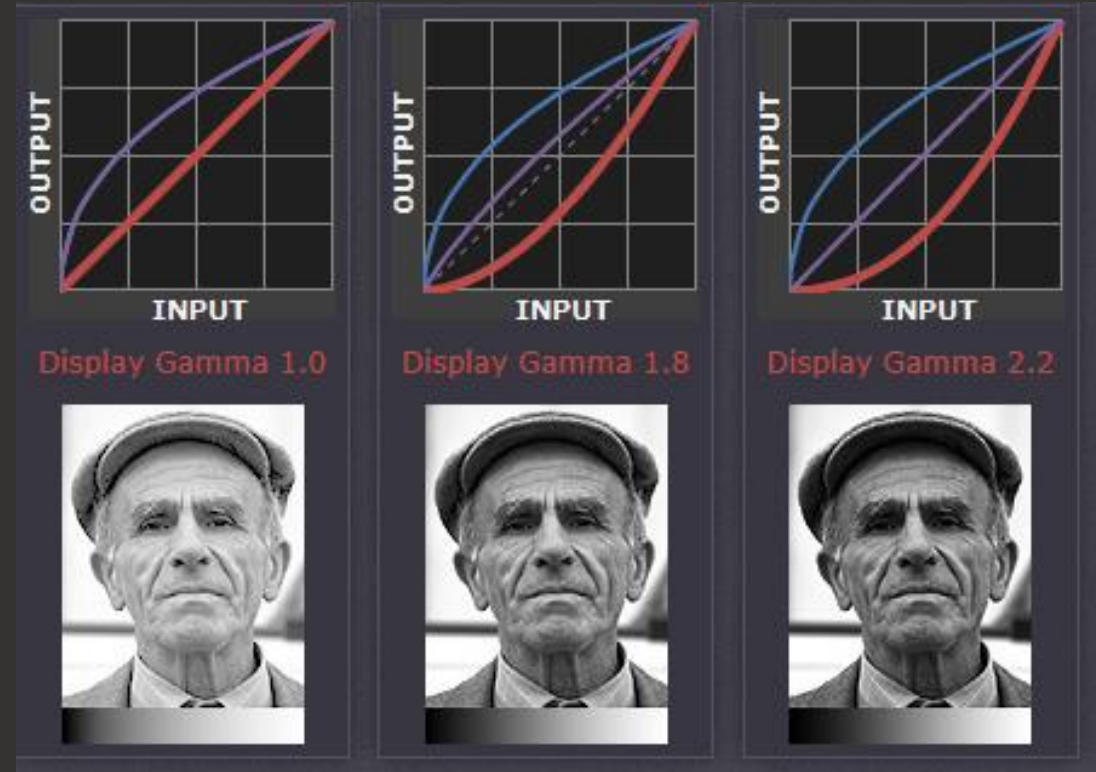
- Las transformaciones de píxel pueden ser también no lineales

$$g(x) = (f(x))^{1/\gamma}$$

Esta transformación es la conocida corrección de gamma (relación entre el valor numérico del píxel y su luminancia real, como la perciben los humanos).

[Ver este link](#)

El valor de γ típico suele ser de 2.2



TRANSFORMACIÓN COLOR A GRISES

1. Promediado (método más común)


$$I_{gris}(i,j) = \frac{R(i,j) + G(i,j) + B(i,j)}{3}$$

2. Brillo (Reducción de contraste)

$$I_{gris}(i,j) = \frac{\max(R(i,j); G(i,j); B(i,j)) - \min(R(i,j); G(i,j); B(i,j))}{2}$$

3. Luminosidad (Buena performance. Usado por GIMP)

$$I_{gris}(i,j) = 0,21R(i,j) + 0,72G(i,j) + 0,07B(i,j)$$




COORDENADAS CROMÁTICAS



- Transformación de imágenes color
 1. Sumar un bias a cada canal no solo modifica el brillo sino el matiz y la saturación (Solución: Modificar solo la luminancia en un espacio de color desacoplado por ej: YIQ o HSV y luego volver al espacio RGB)
 2. Balance de color (por ejemplo, compensar por fuente de luz incandescente) se realiza multiplicando cada canal por un factor de escala diferente.

$$(R, G, B) \rightarrow \left(\frac{R}{R + G + B}; \frac{G}{R + G + B}; \frac{B}{R + G + B} \right)$$

Entonces si $s \in \mathcal{R}$ y $s. (R, G, B) \rightarrow \left(\frac{sR}{sR+sG+sB}; \frac{sG}{sR+sG+sB}; \frac{sB}{sR+sG+sB} \right)$

“**Descriptor** invariante a los cambios de contraste”





COORDENADAS CROMÁTICAS


- Este nuevo descriptor es de dimensión 2, es decir, la proyección sobre el plano $R+G+B=1$

Ec. Plano:

$$\frac{X}{a} + \frac{Y}{b} + \frac{Z}{c} = 1$$

$$a = b = c = (X + Y + Z)$$





ALGORITMO WHITE-PATCH

- Dependiendo el color de la fuente de iluminación tendremos variaciones en los colores reflejados.
- ¿Cómo hacemos para tratar de ser menos susceptibles esto?



ALGORITMO WHITE-PATCH

Original



White Patch






El color de la luz que ilumina la escena puede influir en la percepción que tenemos del objeto, para solventar esto podemos aplicar algoritmos de corrección con procesamiento digital:

- Asumimos que los valores máximos de color en los tres canales es el color del blanco bajo la luz de la escena.
- $R_{max}(Img)$: Valor máximo del canal R de la imagen
- $G_{max}(Img)$: Valor máximo del canal G de la imagen
- $B_{max}(Img)$: Valor máximo del canal B de la imagen

Normalizamos entonces al color de la luz blanca puro (255, 255, 255)

- $(R, G, B) \rightarrow \left(\frac{255}{R_{max}(I)} R, \frac{255}{G_{max}(I)} G, \frac{255}{B_{max}(I)} B \right)$





HISTOGRAMAS

- Un histograma nos dice cómo están distribuidos los valores de intensidad en una imagen
- Permite ver posibles defectos
- Nos interesa modificar la imagen para llevar su histograma a un rango acorde para cada aplicación.



HISTOGRAMAS

La distribución de intensidades en una imagen sin procesar tiende a ser suave y “continua”. Si la imagen fue modificada digitalmente algunas operaciones de píxeles, la alteración de contraste o la compresión se pueden reconocer fácilmente analizando el histograma:





Imagen original (a), histograma luego de aplicar un ligero aumento de contraste (b) y luego de una ligera disminución de contraste (c).




Cambios en el histograma a medida que disminuye el rango dinámico: Cuantización de color.



HISTOGRAMAS

También podemos calcular histogramas N-Dimensionales, por ejemplo entre dos canales de una misma imagen.




En estos casos se cuentan pares de ocurrencias: Si en la posición (30, 20) de la imagen la intensidad de los canales R y G, respectivamente, fue 200 y 10 acumulo 1 en la posición (200, 10) del histograma.




HISTOGRAMAS


Muchas veces un histograma 2D puede aportar información importante que no es fácil de ver en la imagen original:



Podemos ver como el rango dinámico del canal representado en el eje X es mayor al rango del eje Y



Alta correlación entre los valores de intensidad de ambos canales. Podríamos prescindir de canales que no aportan información.





Se observa un efecto de saturación de color en el canal representado por el eje Y




ECUALIZACIÓN DE HISTOGRAMAS

- La idea es “estirar” el histograma para “rellenar” el rango dinámico y a la vez mantener el histograma lo más uniforme posible.
 - Con esto logramos mejorar el contraste y aumentar el rango dinámico
- ¿Cómo lo hacemos?...utilizando la distribución acumulativa (integral del histograma)
 - $c_k = T(r_k) = (L - 1) \sum_{i=0}^k p_r(r_i) = \frac{(L-1)}{N} \sum_{i=0}^k h(i)$
 - N : número de píxels en la imagen
 - r_k : Valor del píxel
 - L : Cantidad de bins o niveles del histograma
 - T : Función de transformación
 - $p_r(r_i) = \frac{n_i}{N}$: Probabilidad de ocurrencia del valor de intensidad r_i en la imagen
 - $h(I)$: Histograma original de la imagen
- `imagen_ecualizada = cv2.equalizeHist(imagen_original)`




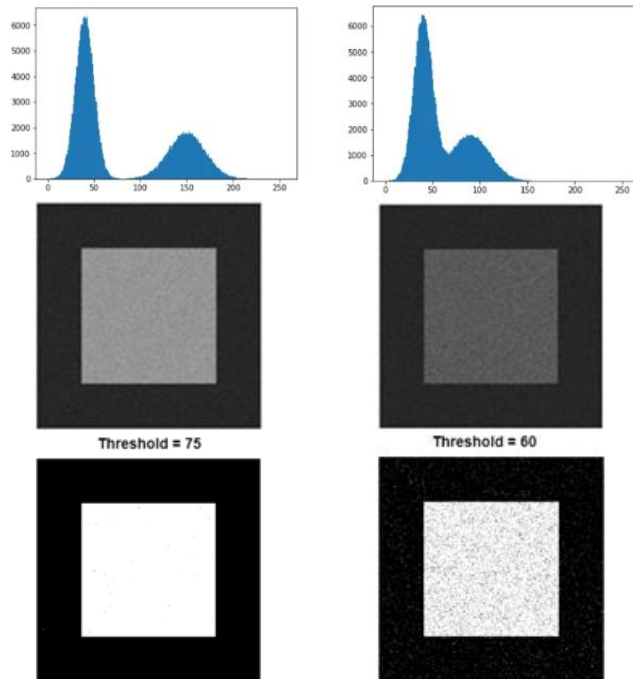
Original



Ecualizada

r_k	n_k	$p_r(r_k)$	s_k	Redondeo
0	2	0,03	0,21	0
1	3	0,05	0,56	1
2	5	0,08	1,12	1
3	6	0,09	1,75	2
4	9	0,14	2,73	3
5	12	0,19	4,06	4
6	14	0,22	5,60	6
7	13	0,20	7,00	7





Original Image



Global Thresholding (v = 127)



Adaptive Mean Thresholding



Adaptive Gaussian Thresholding

BINARIZACIÓN

■ Métodos globales

1. Umbral fijo

$$g(x) = \begin{cases} 1 & \text{si } f(x) \geq T \\ 0 & \text{si } f(x) < T \end{cases}$$

2. Método Otsu

- Calcula el valor de umbral de forma que la dispersión dentro de cada segmento sea lo más pequeña posible, pero al mismo tiempo la dispersión sea lo más alta posible entre segmentos diferentes

■ Métodos locales

1. Mediana

c: por defecto vale 0

$$pixel = (pixel > mediana - c) ? objeto : background$$

1. Niblack

- Basado en la media y varianza local sobre una ventana de tamaño bxb alrededor del píxel

$$pixel = (pixel > media + k * desvio_std - c) ? objeto : background$$

k: por defecto 0.2 para objetos claros, -0.2 para objetos oscuros

c: por defecto (algoritmo original) vale 0

2. Sauvola

- Variación del método anterior

$$pixel = (pixel > media * (1 + k * (desvio_std/r - 1))) ? objeto : background$$

k: por defecto 0.5

r: por defecto 128

3. Bernsen

- El método original usa una ventana circular. Precisa un parámetro de contraste de entrada.

if(contraste local < contraste ingresado)

pixel = (gris medio ≥ 128)? objeto : background

else

pixel = (pixel ≥ gris medio)? objeto : background

4. Más..



BINARIZACIÓN: OTSU


- Método de Otsu (creado por Nobuyuki Otsu)
 - Presupone que el histograma es bimodal y hay una relación de contraste razonable entre fondo y objetos.
 - Busca un valor de umbral que minimice la varianza ponderada dentro de la clase a la vez que maximice la varianza entre clases
 - Digamos que limitamos un histograma a un valor "t". Entonces tendremos dos regiones a izquierda y derecha de "t" con varianzas σ_0^2 y σ_1^2 . Entonces la varianza ponderada vendrá dada por:

$$\sigma_w^2(t) = w_0(t)\sigma_0^2(t) + w_1(t)\sigma_1^2(t)$$

$w_0(t)$ y $w_1(t)$ son los pesos dados a cada clase (proporción de píxeles totales en la clase respecto de los píxeles totales en la imagen).

El problema se reduce a encontrar el mínimo de $\sigma_w^2(t)$. Esto es equivalente a encontrar el máximo de la varianza interclúster:

$$\sigma_B^2(t) = w_0(t)w_1(t)(\mu_0(t) - \mu_1(t))^2$$



$$w_0 = \frac{\text{pix_región}}{\text{pix_totales}} = \frac{6 + 4}{20} = 0.5$$

$$\mu_0 = \frac{\text{Suma pesada int.}}{\text{pix_región}} = \frac{(0 * 6) + (1 * 4)}{10} = 0.4$$


$$\sigma_0^2 = \frac{((0 - 0.4)^2 * 6) + ((1 - 0.4)^2 * 4)}{10} = 0.24$$

$$w_1 = \frac{2 + 8}{20} = 0.5$$

$$\mu_1 = \frac{(2 * 2) + (3 * 8)}{10} = 2.8$$

$$\sigma_1^2 = \frac{((2 - 2.8)^2 * 2) + ((3 - 2.8)^2 * 8)}{10} = 0.16$$

$$\sigma_w^2 = w_0\sigma_0^2 + w_1\sigma_1^2 = 0.5 * 0.24 + 0.5 * 0.16 = 0.2$$



TP1

- Parte 1 (imágenes en `/white_patch` y `/coord_cromaticas`):
 1. Implementar el algoritmo de pasaje a coordenadas cromáticas para librarnos de las variaciones de contraste.
 2. Implementar el algoritmo White Patch para librarnos de las diferencias de color de iluminación.
 3. Mostrar los resultados obtenidos y analizar las posibles fallas (si es que las hay) en el caso de White patch.
- Parte 2:
 1. Para las imágenes `img1_tp.png` y `img2_tp.png` leerlas con OpenCV en escala de grises y visualizarlas.
 2. Elija el numero de bins que crea conveniente y grafique su histograma, compare los histogramas entre si. Explicar lo que se observa, si tuviera que entrenar un modelo de clasificación/detección de imágenes, considera que puede ser de utilidad tomar como 'features' a los histogramas?
 3. Para la imagen `segmentacion.png` analice el histograma de los canales RGB. Segmente algunos de los elementos presentes en la imagen (agua, cielo, tierra) y muestre, aplicando mascarar, las regiones en imágenes separadas.



Resultado luego de aplicar
corrección por coordenadas
cromáticas

